

Progetto SAD

Consiglio Luigi & D'Antuono Francesco Paolo

2024-11-03

Introduzione

Descrizione del problema

Il phishing rappresenta una delle minacce informatiche più diffuse e pericolose, il cui obiettivo è sottrarre informazioni sensibili come credenziali di accesso, numeri di carte di credito e dati personali. Gli attacchi di phishing avvengono principalmente attraverso URL ingannevoli che simulano siti legittimi per indurre gli utenti a fidarsi e condividere i propri dati.

La rilevazione tempestiva degli URL di phishing è essenziale per proteggere gli utenti e ridurre le conseguenze di questi attacchi. Un'analisi statistica delle proprietà degli URL può:

- *Identificare schemi ricorrenti negli URL di phishing*
- *Evidenziare le caratteristiche più influenti per distinguere un URL legittimo da uno fraudolento*

Descrizione del dataset

Il **PhiUSIIL Phishing URL Dataset** è un dataset progettato per lo studio e l'analisi dei siti di phishing. Contiene **23.580 URL** descritti attraverso **56 variabili** che esplorano proprietà tecniche, strutturali e di sicurezza. Ogni URL è accompagnato da una classificazione come **legittimo (1)** o **phishing (0)**.

Le variabili coprono una vasta gamma di caratteristiche, tra cui:

- **Proprietà dell'URL:** lunghezza dell'URL, numero di sottodomini, presenza di caratteri speciali, e frequenza con cui un determinato TLD (Top-Level Domain, come .com) è associato a URL legittimi o di phishing, indicando la probabilità che un TLD specifico sia più o meno affidabile.
- **Caratteristiche testuali:** numero di lettere, numeri e caratteri speciali.
- **Dettagli sul dominio:** lunghezza e struttura del dominio.
- **Elementi strutturali della pagina:** righe di codice, lunghezza della riga più grande, numero di immagini, CSS, JavaScript, reindirizzamenti e popup. Il dataset è particolarmente utile per l'addestramento di modelli di machine learning per la rilevazione del phishing e per analisi statistiche mirate a comprendere i pattern e i fattori di rischio degli URL di phishing.

Obiettivi del Progetto

Questo progetto si propone di rispondere a tre domande di ricerca principali:

1. **Quali caratteristiche degli URL sono maggiormente associate alla probabilità che un sito sia phishing?**

- Variabili analizzate:
 - URLLength (lunghezza dell'URL).
 - NoOfSubDomain (numero di sottodomini).
 - NoOfOtherSpecialCharsInURL (numero di caratteri speciali nell'URL).

Tutte e tre le variabili analizzate sono di tipo discreto ovvero possono assumere solo un insieme finito di valori distinti.

2. **È possibile utilizzare i dati generati dai modelli linguistici di grandi dimensioni (LLM) per migliorare la qualità di dataset reali?** I modelli linguistici di grandi dimensioni, possono essere utilizzati per generare dati sintetici basati su pattern appresi da dataset reali. Questa domanda mira a esplorare se tali dati sintetici possano:

- Arricchire i dataset esistenti, ad esempio simulando URL legittimi o di phishing realistici.

Caricamento del dataset

La prima fase del progetto richiede il caricamento del dataset all'interno dell'ambiente di sviluppo. Dunque, dopo aver settato il workspace, bisogna andarsi a leggere, dalla cartella di lavoro attuale, il dataset che verrà poi analizzato.

```
library(tidyverse)
library(dplyr)
library(stats)

dataset <- read.csv("Phishing_URL_Dataset_8.csv", sep = ";", header = TRUE)
```

Pulizia del dataset

In questa fase, si andrà ad effettuare la pulizia dei dati in modo tale da averli pronti per le successive fasi di analisi del dataset. Vediamo innanzitutto la struttura del dataset.

```
str(dataset)

## 'data.frame': 23580 obs. of 56 variables:
## $ FILENAME : chr "441705.txt" "8023984.txt" "op431.txt" "622028.txt" ...
## $ URL : chr "https://www.sttiggywinkles.org.uk" "http://9837687563--082935.r
## $ URLLength : int 32 32 35 34 45 21 21 20 41 28 ...
## $ Domain : chr "www.sttiggywinkles.org.uk" "9837687563--082935.repl.co" "protoc
## $ DomainLength : int 25 26 27 27 36 14 14 13 32 21 ...
## $ IsDomainIP : int 0 0 0 0 0 0 0 0 0 0 ...
## $ TLD : chr "uk" "co" "pw" "au" ...
## $ URLSimilarityIndex : num 100 23 45.8 100 51.6 ...
## $ CharContinuationRate : num 0.833 0.696 0.667 0.85 0.656 ...
## $ TLDLegitimateProb : num 0.028555 0.005977 0.000167 0.010086 0.522907 ...
## $ URLCharProb : num 0.0477 0.0146 0.0613 0.063 0.0493 ...
## $ TLDDLength : int 2 2 2 2 3 3 3 3 3 2 ...
## $ NoOfSubDomain : int 2 1 1 2 1 1 1 1 1 2 ...
## $ HasObfuscation : int 0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfObfuscatedChar : int 0 0 0 0 0 0 0 0 0 0 ...
## $ ObfuscationRatio : num 0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfLettersInURL : int 18 5 25 20 31 8 8 7 23 15 ...
```

```

## $ LetterRatioInURL      : num  0.562 0.156 0.714 0.588 0.689 0.381 0.381 0.35 0.561 0.536 ...
## $ NoOfDegitsInURL      : int   0 16 0 0 3 0 0 0 6 0 ...
## $ DeditRatioInURL      : num   0 0.5 0 0 0.067 0 0 0 0.146 0 ...
## $ NoOfEqualsInURL      : int   0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfQMarkInURL      : int   0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfAmpersandInURL   : int   0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfOtherSpecialCharsInURL: int  2 4 3 2 3 1 1 1 4 2 ...
## $ SpacialCharRatioInURL : num  0.062 0.125 0.086 0.059 0.067 0.048 0.048 0.05 0.098 0.071 ...
## $ IsHTTPS              : int   1 0 0 1 1 1 1 1 1 0 ...
## $ LineOfCode           : int  2025 198 2 1302 108 1281 3596 527 273 2 ...
## $ LargestLineLength    : int  29601 869 838 9798 8125 1916 4128 9381 20081 37 ...
## $ HasTitle             : int   1 1 0 1 1 1 1 1 1 0 ...
## $ Title                : chr   "sttiggywinklesorg" "9837687563--082935repl" "0" "hrrisonkitchen
## $ DomainTitleMatchScore : num   0 0 0 0 0 100 100 100 0 0 ...
## $ URLTitleMatchScore   : num   0 0 0 0 0 100 100 100 0 0 ...
## $ HasFavicon           : int   1 0 0 1 0 1 1 1 1 0 ...
## $ Robots               : int   1 0 0 1 0 0 0 1 0 0 ...
## $ IsResponsive         : int   1 0 0 1 1 1 1 1 1 0 ...
## $ NoOfURLRedirect      : int   0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfSelfRedirect     : int   0 0 0 0 0 0 0 0 0 0 ...
## $ HasDescription       : int   1 0 0 0 0 0 1 0 0 0 ...
## $ NoOfPopup            : int   0 0 0 0 0 0 0 0 0 0 ...
## $ NoOfiFrame           : int   1 0 0 1 0 0 0 3 0 0 ...
## $ HasExternalFormSubmit : int   0 0 0 0 0 0 0 0 0 0 ...
## $ HasSocialNet         : int   1 0 0 1 0 1 1 1 1 0 ...
## $ HasSubmitButton      : int   1 0 0 0 0 0 0 0 0 0 ...
## $ HasHiddenFields      : int   1 0 0 0 0 0 1 0 1 0 ...
## $ HasPasswordField     : int   0 0 0 0 0 0 0 0 0 0 ...
## $ Bank                 : int   1 0 0 0 0 0 0 0 1 0 ...
## $ Pay                  : int   1 0 0 0 0 0 0 0 1 0 ...
## $ Crypto               : int   0 0 0 0 0 0 0 0 0 0 ...
## $ HasCopyrightInfo     : int   1 0 0 1 0 1 1 1 1 0 ...
## $ NoOfImage            : int   89 0 0 19 0 36 15 9 19 0 ...
## $ NoOfCSS              : int   37 0 0 17 0 6 0 20 3 0 ...
## $ NoOfJS               : int   31 0 1 22 0 12 0 24 9 0 ...
## $ NoOfSelfRef          : int   164 0 1 68 0 130 160 103 1 0 ...
## $ NoOfEmptyRef         : int   0 0 0 0 0 0 2 0 0 0 ...
## $ NoOfExternalRef      : int   187 2 1 71 3 22 165 119 4 0 ...
## $ label                : int   1 0 0 1 0 1 1 1 0 0 ...

```

Come si può notare dai risultati, i tipi dei dati corrispondono alla loro rappresentazione. Ora passiamo a verificare la presenza di righe con valori mancanti.

```
colSums(is.na(dataset))
```

```

##          FILENAME          URL
##              0              0
##      URLLength      Domain
##              0              0
##      DomainLength      IsDomainIP
##              0              0
##              TLD      URLSimilarityIndex
##              0              0

```

##	CharContinuationRate	TLDLegitimateProb
##	0	0
##	URLCharProb	TLDLength
##	0	0
##	NoOfSubDomain	HasObfuscation
##	0	0
##	NoOfObfuscatedChar	ObfuscationRatio
##	0	0
##	NoOfLettersInURL	LetterRatioInURL
##	0	0
##	NoOfDegitsInURL	DegitRatioInURL
##	0	0
##	NoOfEqualsInURL	NoOfQMarkInURL
##	0	0
##	NoOfAmpersandInURL	NoOfOtherSpecialCharsInURL
##	0	0
##	SpacialCharRatioInURL	IsHTTPS
##	0	0
##	LineOfCode	LargestLineLength
##	0	0
##	HasTitle	Title
##	0	0
##	DomainTitleMatchScore	URLTitleMatchScore
##	0	0
##	HasFavicon	Robots
##	0	0
##	IsResponsive	NoOfURLRedirect
##	0	0
##	NoOfSelfRedirect	HasDescription
##	0	0
##	NoOfPopup	NoOfiFrame
##	0	0
##	HasExternalFormSubmit	HasSocialNet
##	0	0
##	HasSubmitButton	HasHiddenFields
##	0	0
##	HasPasswordField	Bank
##	0	0
##	Pay	Crypto
##	0	0
##	HasCopyrightInfo	NoOfImage
##	0	0
##	NoOfCSS	NoOfJS
##	0	0
##	NoOfSelfRef	NoOfEmptyRef
##	0	0
##	NoOfExternalRef	label
##	0	0

Anche in questo caso i risultati ci mostrano che non ci sono righe con valori mancanti all'interno del dataset.

Rimozione feature ridondanti

Abbiamo analizzato nel dettaglio le feature del dataset e si è notato che ci sono alcune feature del dataset che sono ridondanti e che in qualche modo hanno una certa relazione, rappresentando informazioni simili. Dunque, delle 56 variabili che sono presenti nel dataset originale, ne sono rimaste 30, la cui rimozione verrà effettuata di seguito.

```
dataset <- dataset[, !names(dataset) %in% c("FILENAME", "URL", "URLSimilarityIndex",  
"CharContinuationRate", "TLDLegitimateProb", "URLCharProb", "NoOfObfuscatedChar", "ObfuscationRatio", "I
```

La scelta delle feature da rimuovere è stata fatta in base anche alle RQ che la nostra analisi dovrà rispondere, dove sono espresse le feature interessate da ogni RQ.

Analisi dei dati per RQ1


Le feature che metteremo sotto analisi per la RQ1 sono le seguenti:


- **URLLength**: Lunghezza dell'URL;
- **NoOfSubDomain**: I sottodomini sono URL univoci che risiedono sul dominio acquistato, come estensione davanti al dominio normale. Qui viene identificato il numero di caratteri del sottodominio;
- **NoOfOtherSpecialCharsInURL**: Rappresenta il numero di caratteri speciali in un URL. Procediamo con un'analisi esplorativa di queste variabili.

Frequenze assolute per variabili della RQ1

Dopo aver applicato le funzioni di calcolo in R, ecco i risultati ottenuti.

Barplot delle frequenze assolute





Come si può notare dai grafici, i dati sono molto concentrati nella parte sinistra, ciò ci lascia presupporre che probabilmente ci saranno degli outlier da tenere in considerazione. Successivamente analizzeremo in maniera quantitativa i dati, per determinare i valori di questi outlier e dei range più interessanti da prendere in considerazione per le analisi successive.

Indici di sintesi

Indici di centralità

Table 1: Indici di Centralità

	Minimo	Massimo	Media	Mediana	Moda
URLLength	14	1769	35.020483	28	26
NoOfSubDomain	0	8	1.168193	1	1
NoOfOtherSpecialCharsInURL	1	87	2.392918	1	1

Analizziamo nel dettaglio gli indici di centralità per ogni variabile:

- **URLLength:** I dati mostrano una distribuzione asimmetrica positiva, dove la maggior parte degli URL ha lunghezze vicino a 28 (mediana), ma ci sono alcuni URL molto lunghi (fino a 1769), che spostano la media verso l'alto rispetto alla mediana.
- **NoOfSubDomain:** La distribuzione è fortemente concentrata verso il basso. La maggior parte degli URL ha 1 sottodominio (mediana e moda), e solo pochi URL superano questa soglia, con un massimo di 8 sottodomini.

- **NoOfOtherSpecialCharsInURL**: Simile a quella di **NoOfSubDomain**, questa variabile è fortemente concentrata verso il basso, con la maggior parte degli URL che contengono 1 solo carattere speciale. Ci sono però alcuni URL con un numero molto elevato di caratteri speciali (fino a 87), che spostano la media verso l'alto.

Indici di dispersione

Anche in questo caso utilizzeremo le funzioni di R per calcolare gli indici di dispersione per le variabili che stiamo analizzando.

Table 2: Indici di Dispersione

	Range	Varianza	DeviazioneStandard	IQR
URLLength	1755	1141.8893552	33.7918534	10
NoOfSubDomain	8	0.3867401	0.6218843	0
NoOfOtherSpecialCharsInURL	86	8.5974222	2.9321361	2

Analizziamo nel dettaglio gli indici di dispersione per ogni variabile:

- **URLLength**: La varianza riflette anch'essa la variabilità complessiva dei dati, ma è influenzata dagli outlier. Infatti la deviazione standard è moderata rispetto alla media indicando una variabilità significativa, ma non estrema. Dunque, la lunghezza degli URL è distribuita in modo relativamente coerente intorno alla media, con una maggiore densità vicino alla mediana (28).
- **NoOfSubDomain**: La varianza e la deviazione standard sono basse, indicando una distribuzione stretta attorno alla media. Dunque è una variabile poco dispersa, concentrata in un intervallo ristretto, con valori superiori a 1 rari.
- **NoOfOtherSpecialCharsInURL**: La varianza e la deviazione standard riflettono una moderata dispersione intorno alla media. Dunque, la variabile è asimmetrica positiva, con la maggior parte dei dati vicini a 1 e pochi URL con molti caratteri speciali che aumentano la dispersione.

Quartili e Boxplot

Il calcolo dei quartili ci consentirà di capire nel dettaglio la distribuzione dei dati in percentuale.


Table 3: Quartili

	Q0	Q1_25_Percentile	Q2_50_Percentile	Q3_75_Percentile	Q4
URLLength	14	24	28	34	1769
NoOfSubDomain	0	1	1	1	8
NoOfOtherSpecialCharsInURL	1	1	1	3	87

Analizziamo nel dettaglio gli indici di dispersione per ogni variabile:

- **URLLength**: La lunghezza dell'URL ha una distribuzione asimmetrica positiva, con la maggior parte dei dati concentrata tra 24 e 34, ma valori estremamente alti (oltre 1000) che rappresentano eccezioni.
- **NoOfSubDomain**: La concentrazione dei quartili ($Q1 = Q2 = Q3 = 1$) evidenzia che il numero di sottodomini è stabile e poco variabile. Infatti, solo pochi URL oltre Q3 contengono più di 1 sottodominio, con un massimo isolato di 8.

- **NoOfOtherSpecialCharsInURL**: La maggior parte degli URL contiene pochissimi caratteri speciali, con il 75% degli URL che ha al massimo 3 caratteri speciali. La presenza di un massimo di 87 caratteri speciali crea una alta variabilità, come confermato dalla deviazione standard e dal range ampio.



I boxplot sono molto schiacciati e poco visualizzabili, dovuto dalla variabilità elevata dei dati. Ciò ci porta ad analizzare e capire come gestire gli outlier, soprattutto nella variabile **URLLength** e **NoOfOtherSpecialCharsInURL**. Proviamo a rimuovere gli outlier per capire se essi sono significativi per le analisi successive.

Rimozione outlier tramite metodo dell'IQR

Abbiamo già calcolato precedente l'IQR, dunque, ci basta semplicemente quantificare il limite superiore e inferiore, oltre il quale i nostri dati saranno considerati outlier.

```
## Lower Bound URLLength: 9
```

```
## Upper Bound URLLength: 49
```

```
## Lower Bound NoOfOtherSpecialCharsInURL: -2
```

```
## Upper Bound NoOfOtherSpecialCharsInURL: 6
```


Table 4: Summary


Statistic	URLLength	NoOfOtherSpecialCharsInURL
Min	14.00000	1.000000
1st Qu.	23.00000	1.000000
Median	27.00000	1.000000
Mean	27.99753	1.892295
3rd Qu.	31.00000	2.000000
Max	49.00000	6.000000

Dopo la rimozione degli outlier, si può notare che c'è stata una notevole variazione degli indici statistici, ciò potrebbe comportare che gli outlier in realtà sono significativi e non devono essere rimossi per le analisi che dovremo condurre. Andiamo a confrontare le distribuzioni per evidenziare ulteriori differenze.


Confronto distribuzioni pre e post-filtraggio

Per confrontare le distribuzioni, andremo a rappresentare dei barplot pre e post-filtraggio e compararli per capire l'andamento dei dati.





NoOfOtherSpecialCharsInURL



NoOfOtherSpecialCharsInURL senza outli

Come è possibile vedere dai grafici, le distribuzioni dei dati, anche se sono molto più visibili, non sono confrontabili, poiché sono distribuzioni differenti che spostano la centralità dei dati, cambiandone il significato. Dunque è molto probabile che gli outliers in realtà sono dati significativi che non bisogna rimuovere. Andiamo a calcolare le probabilità che un sito sia di phishing oppure legittimo, pre e post-filtraggio. Ciò ci darà un ottimo indizio sull'importanza degli outliers e quindi su come dovranno essere trattati.

Table 5: Percentuali phishing

Dataset	Phishing	Legittimo
Originale	0.4305768	0.5694232
Senza Outlier URLLength	0.3627735	0.6372265
Senza Outlier NoOfOtherSpecialCharsInURL	0.3974330	0.6025670

Le probabilità mostrano un decremento della presenza di URL di phishing sia nel caso in cui vi è la rimozione degli outlier di **URLLength** che di **NoOfOtherSpecialCharsInURL**. Ciò dimostra che i dati rimossi hanno un'importante significato nell'individuazione degli URL di phishing o legittimi.

```
# Calcolo frequenze relative nel dataset con soli outliers per URLLength
outliers_url <- dataset %>% filter(URLLength > 49)


frequenze_relative_url_label_outliers <- table(outliers_url$label) / nrow(outliers_url)

# Calcolo frequenze relative nel dataset con soli outliers per NoOfOtherSpecialCharsInURL
outliers_special_chars <- dataset %>% filter(NoOfOtherSpecialCharsInURL > 6)
```


```

frequenze_relative_special_chars_label_outliers <- table(outliers_special_chars$label) / nrow(outliers_s
par(mfrow=c(1,2))
barplot(
  frequenze_relative_url_label_outliers,
  xlab = "label con URLLength > 49",
  ylab = "Frequenze Relative",
  col = "green",
  border = "black"
)
barplot(
  frequenze_relative_special_chars_label_outliers,
  xlab = "label con NoOfOtherSpecialCharsInURL > 6",
  ylab = "Frequenze Relative",
  col = "green",
  border = "black"
)

```



label con URLLength > 49



label con NoOfOtherSpecialCharsInURL :

Andando a filtrare i dataset solo per gli outlier esclusi, notiamo come ci sia una probabilità di phishing del 100%, per i dati al di fuori dell'upper bound, ciò indica che sia URL molto lunghi che URL con molti caratteri speciali, portano a URL di phishing.