

Progetto SAD

Consiglio Luigi & D'Antuono Francesco Paolo

10/02/2025

Indice

Introduzione	3
Descrizione del problema	3
Descrizione del dataset	3
Obiettivi del Progetto	4
Caricamento e pulizia del dataset	4
Rimozione feature ridondanti	5
Statistica descrittiva univariata	6
Analisi dei dati per RQ1	6
Frequenze assolute e barplot	6
Indici di centralità	8
Indici di dispersione	8
Quartili e Boxplot	8
Rimozione outlier tramite metodo dell'IQR	10
Confronto distribuzioni pre e post-filtraggio	10
Analisi statistica comparativa	13
Confronto distribuzioni dataset phishing e dataset legittimo	13
Statistica descrittiva multivariata	17
Matrice di correlazione	17
Modello di regressione lineare	18
Coefficiente di determinazione	18
Analisi dei cluster	19
Analisi dei dati per RQ2	19
Metodo dell'Elbow	19
Metodo della Silhouette	20
Applicazione del K-means con ripetizione della procedura di scelta casuale dei punti di riferimento	20
Analisi della bontà del clustering	20
Analisi descrittiva dei cluster	21
Grafici per confronto cluster	21
Applicazione del K-means con scelta dei centroidi usando metodo gerarchico	22
Analisi della bontà del clustering	22
Analisi descrittiva dei cluster	23
Grafici per confronto cluster	23
Caricamento e pulizia dataset generato da ChatGPT	24

Analisi dei cluster dataset generato da chatGPT	24
Metodo dell'Elbow	25
Metodo della Silhouette	26
Applicazione del K-means	26
Analisi della bontà del clustering	26
Analisi descrittiva dei cluster generati da ChatGPT	27
Grafici per confronto cluster	27
Inferenza Statistica	31
Stima dei parametri	31
Regressione logistica	31
Verifica delle ipotesi	32
Applicazione criterio del chi quadro per distribuzione normale	32
Applicazione criterio del chi quadro per distribuzione di Bernoulli	33
Test Chi-Quadrato su URLLength	33
Test Chi-Quadrato su NoOfOtherSpecialCharsInURL	34
Conclusioni	34

Introduzione

Descrizione del problema

Il phishing rappresenta una delle minacce informatiche più **diffuse e pericolose**, il cui obiettivo è sottrarre informazioni sensibili come credenziali di accesso, numeri di carte di credito e dati personali. Gli attacchi di phishing avvengono principalmente attraverso URL ingannevoli che simulano siti legittimi per indurre gli utenti a fidarsi e condividere i propri dati.

La rilevazione tempestiva degli URL di phishing è essenziale per proteggere gli utenti e ridurre le conseguenze di questi attacchi. Un'analisi statistica delle proprietà degli URL può:

- **Identificare schemi ricorrenti negli URL di phishing;**
- **Evidenziare le caratteristiche più influenti per distinguere un URL legittimo da uno fraudolento.**

Descrizione del dataset

Il **PhiUSIIL Phishing URL Dataset** è un dataset progettato per lo studio e l'analisi dei siti di phishing. Contiene **23.580 URL** descritti attraverso **56 variabili** che esplorano proprietà tecniche, strutturali e di sicurezza. Ogni URL è accompagnato da una classificazione come **legittimo (1)** o **phishing (0)**.

Le variabili coprono una vasta gamma di caratteristiche, tra cui:

- **Proprietà dell'URL:** lunghezza dell'URL, numero di sottodomini, presenza di caratteri speciali, e frequenza con cui un determinato TLD (Top-Level Domain, come `.com`) è associato a URL legittimi o di phishing, indicando la probabilità che un TLD specifico sia più o meno affidabile.
- **Caratteristiche testuali:** numero di lettere, numeri e caratteri speciali.
- **Dettagli sul dominio:** lunghezza e struttura del dominio.
- **Elementi strutturali della pagina:** righe di codice, lunghezza della riga più grande, numero di immagini, CSS, JavaScript, reindirizzamenti e popup. Il dataset è particolarmente utile per l'addestramento di modelli di machine learning per la rilevazione del phishing e per analisi statistiche mirate a comprendere i pattern e i fattori di rischio degli URL di phishing.

Obiettivi del Progetto

Questo progetto si propone di rispondere a due domande di ricerca principali:

1. **Quali caratteristiche degli URL sono maggiormente associate alla probabilità che un sito sia di phishing?**
 - Variabili analizzate:
 - **URLLength**: Lunghezza dell'URL;
 - **NoOfSubDomain**: Numero di sottodomini;
 - **NoOfOtherSpecialCharsInURL**: Numero di caratteri speciali nell'URL;
 - **label**: Classificazione dell'URL (0 phishing, 1 legittimo).

Tutte le variabili analizzate sono di tipo discreto ovvero possono assumere solo un insieme finito di valori distinti.

2. **È possibile utilizzare i dati generati dai modelli linguistici di grandi dimensioni (LLM) per migliorare la qualità di dataset reali?** I modelli linguistici di grandi dimensioni, possono essere utilizzati per generare dati sintetici basati su pattern appresi da dataset reali. Questa domanda mira a esplorare se tali dati sintetici possano arricchire i dataset esistenti (ad esempio simulando URL legittimi o di phishing realistici).

Caricamento e pulizia del dataset

La prima fase del progetto richiede il caricamento del dataset all'interno dell'ambiente di sviluppo. Dunque, dopo aver settato il workspace, bisogna andarsi a leggere, dalla cartella di lavoro attuale, il dataset che verrà poi analizzato.

Inoltre, si andrà ad effettuare la pulizia dei dati in modo tale da averli pronti per le successive fasi di analisi del dataset. Sono stati effettuati due controlli fondamentali:

- **Controllo tipi di dati**: Abbiamo innanzitutto controllato che i tipi di dati corrispondessero con la loro rappresentazione nella colonna specifica. I risultati hanno dato esito positivo e non c'è stato bisogno di modificare il dataset.
- **Controllo valori mancanti**: Anche in questo caso il controllo ha dato esito positivo. Dunque non ci sono righe con valori mancanti all'interno del dataset.

Rimozione feature ridondanti

Abbiamo analizzato nel dettaglio le feature del dataset e si è notato che ci sono alcune feature del dataset che sono ridondanti e che in qualche modo hanno una certa relazione, rappresentando informazioni simili. Dunque, delle **56** variabili che sono presenti nel dataset originale, ne sono rimaste **30**, elencate di seguito in una tabella.

Table 1: Variabili Rimosse dal Dataset

	Tipo_variabale
FILENAME	character
URL	character
URLSimilarityIndex	numeric
CharContinuationRate	numeric
TLDLegitimateProb	numeric
URLCharProb	numeric
NoOfObfuscatedChar	integer
ObfuscationRatio	numeric
LetterRatioInURL	numeric
DegitRatioInURL	numeric
SpacialCharRatioInURL	numeric
Title	character
DomainTitleMatchScore	numeric
HasFavicon	integer
Robots	integer
NoOfURLRedirect	integer
NoOfSelfRedirect	integer
HasSubmitButton	integer
HasPasswordField	integer
HasCopyrightInfo	integer
NoOfImage	integer
NoOfCSS	integer
NoOfJS	integer
NoOfSelfRef	integer
NoOfEmptyRef	integer
NoOfExternalRef	integer

Statistica descrittiva univariata


Analisi dei dati per RQ1


Le feature che metteremo sotto analisi per la RQ1 sono le seguenti:

- **URLLength**: Lunghezza dell'URL;
- **NoOfSubDomain**: I sottodomini sono URL univoci che risiedono sul dominio acquistato, come estensione davanti al dominio normale. Qui viene identificato il numero di caratteri del sottodominio;
- **NoOfOtherSpecialCharsInURL**: Rappresenta il numero di caratteri speciali in un URL. Procediamo con un'analisi esplorativa di queste variabili.
- **label**: Classificazione dell'URL (0 phishing, 1 legittimo).

Frequenze assolute e barplot

Di seguito vengono mostrati i grafici delle frequenze assolute.





Come si può notare dai grafici, i dati sono molto concentrati nella parte sinistra, ciò ci lascia presupporre che probabilmente ci saranno degli **outlier** da tenere in considerazione. Successivamente analizzeremo in maniera quantitativa i dati, per determinare i valori di questi outlier e dei range più interessanti da prendere in considerazione per le analisi successive.

Indici di centralità

Table 2: Indici di Centralità

	Minimo	Massimo	Media	Mediana	Moda
URLLength	14	1769	35.020483	28	26
NoOfSubDomain	0	8	1.168193	1	1
NoOfOtherSpecialCharsInURL	1	87	2.392918	1	1

Analizziamo nel dettaglio gli indici di centralità per ogni variabile:

- **URLLength:** I dati mostrano una distribuzione asimmetrica positiva, dove la maggior parte degli URL ha lunghezze vicino a 28 (mediana), ma ci sono alcuni URL molto lunghi (fino a 1769), che spostano la media verso l'alto rispetto alla mediana.
- **NoOfSubDomain:** La distribuzione è fortemente concentrata verso il basso. La maggior parte degli URL ha 1 sottodominio (mediana e moda), e solo pochi URL superano questa soglia, con un massimo di 8 sottodomini.
- **NoOfOtherSpecialCharsInURL:** Simile a quella di **NoOfSubDomain**, questa variabile è fortemente concentrata verso il basso, con la maggior parte degli URL che contengono 1 solo carattere speciale. Ci sono però alcuni URL con un numero molto elevato di caratteri speciali (fino a 87), che spostano la media verso l'alto.

Indici di dispersione

Table 3: Indici di Dispersione

	Range	Varianza	DeviazioneStandard	IQR
URLLength	1755	1141.8893552	33.7918534	10
NoOfSubDomain	8	0.3867401	0.6218843	0
NoOfOtherSpecialCharsInURL	86	8.5974222	2.9321361	2

Analizziamo nel dettaglio gli indici di dispersione per ogni variabile:

- **URLLength:** La varianza riflette anch'essa la variabilità complessiva dei dati, ma è influenzata dagli outlier. Infatti la deviazione standard è moderata rispetto alla media indicando una variabilità significativa, ma non estrema. Dunque, la lunghezza degli URL è distribuita in modo relativamente coerente intorno alla media, con una maggiore densità vicino alla mediana.
- **NoOfSubDomain:** La varianza e la deviazione standard sono basse, indicando una distribuzione stretta attorno alla media. Dunque è una variabile poco dispersa, concentrata in un intervallo ristretto, con valori superiori a 1 rari.
- **NoOfOtherSpecialCharsInURL:** La varianza e la deviazione standard riflettono una moderata dispersione intorno alla media. Dunque, la variabile è asimmetrica positiva, con la maggior parte dei dati vicini a 1 e pochi URL con molti caratteri speciali che aumentano la dispersione.

Quartili e Boxplot


Il calcolo dei quartili ci consentirà di capire nel dettaglio la distribuzione dei dati in percentuale.

Table 4: Quartili

	Q0	Q1_25_Percentile	Q2_50_Percentile	Q3_75_Percentile	Q4
URLLength	14	24	28	34	1769
NoOfSubDomain	0	1	1	1	8
NoOfOtherSpecialCharsInURL	1	1	1	3	87

Analizziamo nel dettaglio i quartili per ogni variabile:

- **URLLength**: Abbiamo conferma che la lunghezza dell'URL ha una distribuzione asimmetrica positiva, con la maggior parte dei dati concentrata tra 24 e 34, ma valori estremamente alti (oltre 1000) che rappresentano eccezioni.
- **NoOfSubDomain**: La concentrazione dei quartili ($Q1 = Q2 = Q3 = 1$) evidenzia che il numero di sottodomini è stabile e poco variabile. Infatti, solo pochi URL oltre Q3 contengono più di 1 sottodominio, con un massimo isolato di 8.
- **NoOfOtherSpecialCharsInURL**: La maggior parte degli URL contiene pochissimi caratteri speciali, con il 75% degli URL che ha al massimo 3 caratteri speciali. La presenza di un massimo di 87 caratteri speciali crea una alta variabilità, come confermato dalla deviazione standard e dal range ampio.



I boxplot sono molto schiacciati e poco visualizzabili, dovuto dalla variabilità elevata dei dati. Ciò ci porta ad analizzare e capire come gestire gli outlier, soprattutto nella variabile **URLLength** e **NoOfOtherSpecialCharsInURL**. Proviamo a rimuovere gli outlier per capire se essi sono significativi per le analisi successive.

Rimozione outlier tramite metodo dell'IQR

Abbiamo già calcolato precedente l'IQR, dunque, ci basta semplicemente **quantificare il limite superiore e inferiore**, oltre il quale i nostri dati saranno considerati outlier.

Table 5: Limiti per URLLength e NoOfOtherSpecialCharsInURL

	Limiti	URLLength	NoOfOtherSpecialCharsInURL
25%	Limite inferiore	9	-2
75%	Limite superiore	49	6

Table 6: Summary


Statistica	URLLength	NoOfOtherSpecialCharsInURL
Min	14.00000	1.000000
1st Qu.	23.00000	1.000000
Median	27.00000	1.000000
Mean	27.99753	1.892295
3rd Qu.	31.00000	2.000000
Max	49.00000	6.000000

Dopo la rimozione degli outlier, si può notare che c'è stata una notevole variazione degli indici statistici, ciò potrebbe comportare che gli outlier in realtà sono significativi e non devono essere rimossi per le analisi che dovremo condurre. Andiamo a confrontare le distribuzioni per evidenziare ulteriori differenze.


Confronto distribuzioni pre e post-filtraggio


Per confrontare le distribuzioni, andremo a rappresentare dei barplot pre e post-filtraggio e compararli per capire l'andamento dei dati.

Dataset originale



Dataset senza outliers






Come è possibile vedere dai grafici, le distribuzioni dei dati, anche se sono molto più visibili, non sono confrontabili, poiché sono distribuzioni differenti che spostano la centralità dei dati, cambiandone il significato. Dunque è molto probabile che gli outliers in realtà sono dati significativi che non bisogna rimuovere. Andiamo a calcolare le probabilità che un sito sia di phishing oppure legittimo, pre e post-filtraggio. Ciò ci darà un ottimo indizio sull'importanza degli outliers e quindi su come dovranno essere trattati.

Table 7: Percentuali di phishing

Dataset	Phishing	Legittimo
Originale	0.4305768	0.5694232
Senza Outlier URLLength	0.3627735	0.6372265
Senza Outlier NoOfOtherSpecialCharsInURL	0.3974330	0.6025670

Le probabilità mostrano un decremento della presenza di URL di phishing sia nel caso in cui vi è la rimozione degli outlier di **URLLength** che di **NoOfOtherSpecialCharsInURL**. Ciò dimostra che i dati rimossi hanno un'importante significato nell'individuazione degli URL di phishing o legittimi.





Andando a filtrare i dataset solo per gli outlier esclusi, notiamo come ci sia una probabilità di phishing del 100%, per i dati al di fuori dell'upper bound (i quali sono 2509), ciò indica che sia URL molto lunghi che URL con molti caratteri speciali, portano a URL di phishing. Ciò ci porta a mantenere gli outlier e ci da un primo indizio su una **possibile correlazione** tra queste due variabili.

Analisi statistica comparativa

In questa sezione viene condotta un'analisi esplorativa comparativa, in cui viene diviso il dataset in 2 sub-dataset, uno contenente solo gli URL legittimi ed uno solo gli URL di phishing. Qui vengono comparati gli indici di centralità e dispersione dei due subdataset per comprendere meglio la distribuzione dei dati nei due casi distinti.

Confronto distribuzioni dataset phishing e dataset legittimo

Per confrontare le distribuzioni, andremo a rappresentare dei barplot per il dataset di phishing e per il dataset legittimo, in modo da capire l'andamento dei dati.






Table 8: Statistiche descrittive per i siti legittimi

Variabile	Media	Mediana	Deviazione_Standard	Minimo	Massimo
URLLength	26.271915	26	4.7929594	16	49
NoOfSubDomain	1.163700	1	0.4051827	1	4
NoOfOtherSpecialCharsInURL	1.252923	1	0.5135634	1	5

Table 9: Statistiche descrittive per i siti di phishing

Variabile	Media	Mediana	Deviazione_Standard	Minimo	Massimo
URLLength	46.590170	34	48.853538	14	1769
NoOfSubDomain	1.174136	1	0.825264	0	8
NoOfOtherSpecialCharsInURL	3.900522	3	3.953178	1	87

Dall'analisi dei dati emergono alcune differenze chiave tra i siti legittimi e quelli di phishing rispetto alle variabili esaminate.

1. URLLength:

- **Media:** I siti di phishing hanno una lunghezza media degli URL significativamente maggiore (46.59) rispetto ai siti legittimi (26.27).
- **Mediana:** La mediana degli URL phishing (34) è più alta rispetto ai siti legittimi (26), confermando che i siti di phishing tendono ad avere URL più lunghi.

- **Dispersione:** La deviazione standard è molto più elevata per i siti di phishing (48.85) rispetto ai siti legittimi (4.79), indicando una forte variabilità nella lunghezza degli URL dei siti fraudolenti.
- **Estremi:** Il valore massimo per gli URL di phishing (1769 caratteri) è estremamente elevato rispetto ai siti legittimi (49 caratteri), suggerendo che alcuni attacchi di phishing usano URL molto lunghi per ingannare gli utenti.

Quindi possiamo notare che la lunghezza dell'URL è un forte indicatore di phishing, con URL significativamente più lunghi e più variabili nei siti fraudolenti.

2. NoOfSubDomain:

- **Media:** La differenza è minima tra siti legittimi (1.16) e siti phishing (1.17), suggerendo che questa caratteristica non è particolarmente discriminante.
- **Mediana:** Identica per entrambe le categorie (1), confermando che la maggior parte degli URL ha un solo sottodominio.
- **Dispersione:** La deviazione standard è più alta nei siti di phishing (0.83) rispetto ai siti legittimi (0.40), il che indica una maggiore variabilità nei siti fraudolenti.
- **Estremi:** I siti di phishing hanno un minimo di 0 sottodomini e un massimo di 8, mentre i siti legittimi variano da 1 a 4.

Qui notiamo che il numero di sottodomini non sembra un forte predittore di phishing, ma nei siti fraudolenti c'è una maggiore variabilità.

3. NoOfOtherSpecialCharsInURL:


- **Media:** I siti di phishing contengono una media molto più alta di caratteri speciali (3.90) rispetto ai siti legittimi (1.25).
- **Mediana:** Anche la mediana è maggiore nei siti phishing (3 vs 1).
- **Dispersione:** La deviazione standard nei siti di phishing è molto elevata (3.95) rispetto a quelli legittimi (0.51), confermando che alcuni URL fraudolenti possono contenere un numero elevato di caratteri speciali.
- **Estremi:** I siti di phishing hanno un massimo di 87 caratteri speciali, mentre i siti legittimi arrivano al massimo a 5.

Da ciò si evince che un numero elevato di caratteri speciali nell'URL è un forte indicatore di phishing, poiché gli URL fraudolenti tendono ad avere più simboli rispetto ai siti legittimi.

Statistica descrittiva multivariata


Matrice di correlazione

La correlazione è una misura statistica che descrive la relazione tra due variabili, vogliamo utilizzarla per vedere se ci sono relazioni tra le variabili in esame.



Dalla matrice di correlazione, possiamo notare che c'è una **correlazione positiva tra URLLength e NoOfOtherSpecialCharsInURL**. Questo risultato ci porta a voler analizzare meglio la relazione tra queste due variabili attraverso l'utilizzo di uno Scatterplot.

Modello di regressione lineare



La linea di regressione rossa suggerisce una forte relazione positiva, indicando che all'aumentare della lunghezza dell'URL aumenta anche il numero di caratteri speciali. Questo suggerisce che gli URL più lunghi tendono a contenere più caratteri speciali, una caratteristica comune negli attacchi di phishing, in cui i truffatori usano URL complessi per mascherare l'indirizzo reale. //Aggiungere altre variabili per vedere se aumenta la bontà di adattamento

Coefficiente di determinazione

Siamo interessati a vedere quanto la retta di regressione si adatta ai dati, per farlo utilizziamo il coefficiente di determinazione.

Esso sarà $R^2 = 0.6222$, ciò significa che il 62.22% della variabilità nel numero di caratteri speciali può essere spiegata dalla lunghezza dell'URL. Non è un modello perfetto, ma mostra una correlazione moderatamente forte: c'è una tendenza chiara, anche se non tutti i punti seguono perfettamente la retta di regressione.

Si può concludere che la lunghezza dell'URL è un buon indicatore, ma non è l'unico fattore che determina il numero di caratteri speciali negli URL.

Analisi dei cluster

Analisi dei dati per RQ2


Per effettuare il clustering, dobbiamo innanzitutto scegliere il tipo di clustering che si vuole applicare. Nel nostro caso abbiamo scelto l'**algoritmo non gerarchico K-Means**.

Dalle analisi precedenti, è stata individuata **URLLength** come variabile che influenza molto la probabilità che un URL sia di phishing oppure legittimo, dunque utilizzeremo questa variabile per il clustering, poiché risulta essere la più significativa. Ciò ci servirà per individuare possibili pattern nascosti che non siamo riusciti ad individuare fino ad ora e dare ancora più importanza alle nostre ipotesi, derivate dalle analisi passate.

Prima di passare all'applicazione del clustering, dobbiamo derivare quale è il k ottimale di cluster da utilizzare per l'algoritmo.


Metodo dell'Elbow

Per scegliere il numero ottimale di cluster, utilizzeremo il **metodo dell'Elbow**, che analizza la riduzione del **Within-Cluster Sum of Squares (WCSS)** al variare di K . Dal grafico ottenuto, individueremo il **punto di flessione** in cui la riduzione del WCSS rallenta, suggerendo il numero ideale di cluster. Se necessario, possiamo confermare la scelta con altre metriche come il **Silhouette Score**.



Dal grafico del metodo dell'Elbow, il punto di flessione sembra situarsi intorno a $K = 2$ o $K = 3$, poiché dopo questi valori la riduzione del **WCSS** diventa meno significativa. Tuttavia, per confermare la scelta ottimale del numero di cluster, vogliamo calcolare il **Silhouette Score**, che ci permetterà di valutare la coesione e la separabilità dei cluster in modo più quantitativo.

Metodo della Silhouette



Sulla base dei risultati della **silhouette** e del **metodo dell'elbow**, il numero ottimale di cluster è **2**. Poiché entrambi i metodi confermano questa scelta, possiamo procedere con il **k-means con $k = 2$** per segmentare i dati in due gruppi distinti basati sulla variabile `URLLength`.

Applicazione del K-means con ripetizione della procedura di scelta casuale dei punti di riferimento

L'applicazione del k-means è stata fatta, come già spiegato, con **$k = 2$** , utilizzando come riferimento sia il metodo dell'elbow che il metodo della silhouette. Abbiamo inoltre utilizzato un **nstart = 10**, poiché il k-means dipende dalla scelta casuale dei centroidi iniziali e per mitigare questo problema abbiamo eseguito l'algoritmo 10 volte differenti, prelevando il **minor errore quadratico totale (WCSS)**, tra tutti i risultati ottenuti.

Analisi della bontà del clustering

Abbiamo deciso di calcolare alcune **metriche di bontà** per valutare la qualità del clustering ottenuto con K-Means. In particolare, abbiamo analizzato i **centroidi dei cluster**, la **varianza interna ai cluster (WCSS)**, la **separazione tra i cluster (BCSS)** e l'**indice di Calinski-Harabasz**, che confronta i due valori per misurare l'efficacia della suddivisione.

Table 10: Risultati del Clustering

Metriche	Valori
Centroide Cluster 1	32.56506
Centroide Cluster 2	282.12931
Centroide Globale	35.02048
WCSS	12617278.29591
BCSS	14307330.81058
Calinski-Harabasz	26736.21346
numero elementi Cluster 1	23348.00000
numero elementi Cluster 2	232.00000

Dai risultati emerge che i due cluster individuati sono sbilanciati a causa della distribuzione dei dati, con centroidi molto distanti tra loro.

Nonostante lo sbilanciamento tra i cluster, l'analisi delle metriche conferma che il clustering è significativo e ben separato, dato che il valore elevato della **BCSS** indica che i cluster sono ben separati, mentre la **WCSS** mostra una certa dispersione interna. L'**indice di Calinski-Harabasz** è molto alto, confermando che il clustering è ben strutturato e che la divisione in due gruppi è significativa.

In conclusione, il clustering risulta essere efficace, con gruppi ben separati e una buona coesione interna.

Analisi descrittiva dei cluster

Dopo aver valutato la bontà dei cluster, andiamo a determinare in maniera quantitativa, come sono state divise le osservazioni del dataset.

Table 11: Statistiche descrittive per i due cluster

Clusters	Minimo	Massimo	Media	Mediana	Deviazione_Standard
Cluster1	14	157	32.56506	28	16.73097
Cluster2	158	1769	282.12931	232	162.26031


I due cluster assumono un significato più importante dopo aver visualizzato gli indici di centralità e di dispersione, infatti avremo che:

- **Cluster1:** Questo cluster contiene URL significativamente più lunghi, con un'alta variabilità (deviazione standard elevata). La mediana è inferiore alla media, indicando la presenza di URL estremamente lunghi che alzano la media. Dunque, in questo cluster sono stati raggruppati tutti gli URL più lunghi che sono di phishing, dove sono inclusi anche gli outliers.
- **Cluster2:** Gli URL in questo cluster sono molto più corti e hanno una distribuzione più compatta, con una bassa variabilità. La media e la mediana sono vicine, segnalando una distribuzione più simmetrica rispetto al Cluster 1. Il Cluster 2 rappresenta dunque URL più corti, che potrebbero essere più tipici di siti legittimi.

Grafici per confronto cluster

Andiamo a visualizzare le distribuzioni in maniera grafica, per avere una visione più diretta ed esplicativa della differenza tra i due cluster.

Distribuzione dei dati di URLLength per Cluster



In questi due grafici, si nota ancora di più la netta distinzione che c'è tra i due cluster, dove il Cluster2 ha url più corti, mentre il Cluster1 ha url molto più lunghi.

Applicazione del K-means con scelta dei centroidi usando metodo gerarchico

Anche in questo caso utilizziamo $k = 2$, utilizzando come riferimento sia il metodo dell'elbow che il metodo della silhouette. Qui abbiamo utilizzato un **approccio gerarchico** per ottenere i centroidi iniziali, applicando un clustering gerarchico e utilizzando i centroidi dei cluster risultanti come punti di partenza per il **K-Means**. Questo metodo permette di selezionare i centroidi in modo più mirato, migliorando la stabilità del clustering e riducendo la dipendenza dalla scelta casuale iniziale.

```
## [1] 34.90584 1386.50000
```

Analisi della bontà del clustering

Abbiamo deciso di calcolare alcune **metriche di bontà** per valutare la qualità del clustering ottenuto con K-Means. In particolare, abbiamo analizzato i **centroidi dei cluster**, la **varianza interna ai cluster (WCSS)**, la **separazione tra i cluster (BCSS)** e l'**indice di Calinski-Harabasz**, che confronta i due valori per misurare l'efficacia della suddivisione.

Table 12: Risultati del Clustering

Metriche	Valori
Centroidi Cluster 1	32.79122
Centroidi Cluster 2	306.57292
Centroidi Globale	35.02048
WCSS	12650160.49529
BCSS	14274448.61120
Calinski-Harabasz	26605.42919
numero elementi Cluster 1	23388.00000
numero elementi Cluster 2	192.00000

Anche in questo caso dai risultati emerge che i due cluster individuati sono sbilanciati a causa della distribuzione dei dati, con centroidi molto distanti tra loro.

Nonostante lo sbilanciamento tra i cluster, l'analisi delle metriche conferma che il clustering è significativo e ben separato, dato che il valore elevato della **BCSS** indica che i cluster sono ben separati, mentre la **WCSS** mostra una certa dispersione interna. L'**indice di Calinski-Harabasz** è molto alto, confermando che il clustering è ben strutturato e che la divisione in due gruppi è significativa.

Le metriche indicano che i cluster sono ben separati dato dal valore elevato della BCSS, ma c'è ancora dispersione interna come mostra la WCSS. L'indice di Calinski-Harabasz conferma una buona qualità del clustering, anche se leggermente inferiore alla precedente esecuzione.

Analisi descrittiva dei cluster

Dopo aver valutato la qualità del clustering, analizziamo in modo quantitativo come le osservazioni del dataset sono state suddivise tra i cluster.

Table 13: Statistiche descrittive per i due cluster

Clusters	Minimo	Massimo	Media	Mediana	Deviazione_Standard
Cluster1	14	169	32.79122	28.0	17.58748
Cluster2	171	1769	306.57292	247.5	168.39406

L'analisi delle statistiche descrittive mostra una chiara distinzione tra i due cluster. Il Cluster 1 raccoglie gli URL più lunghi. Gli URL in questo gruppo variano tra 158 e 1769 caratteri, con una mediana di 232, indicando una distribuzione molto ampia.


Il Cluster 2, invece, rappresenta gli URL più corti e omogenei, con una media di 32 caratteri e una deviazione standard molto più bassa. La lunghezza degli URL in questo gruppo varia tra 14 e 157 caratteri, con una mediana di 28, segnalando una distribuzione più compatta.

Questi risultati confermano che il clustering ha separato efficacemente gli URL lunghi da quelli più corti, con il Cluster 1 caratterizzato da una maggiore dispersione e il Cluster 2 da una struttura più uniforme.

Grafici per confronto cluster

Andiamo a visualizzare le distribuzioni in maniera grafica, per avere una visione più diretta ed esplicativa della differenza tra i due cluster.

Distribuzione dei dati di URLLength per Cluster



Questi due grafici evidenziano ancora meglio la chiara separazione tra i due cluster: il **Cluster 2** comprende URL più brevi, mentre il **Cluster 1** contiene URL significativamente più lunghi.

Caricamento e pulizia dataset generato da ChatGPT

Qui applicheremo gli stessi processi iniziali applicati sul dataset principale, per capire se il dataset ha generato in maniera corretta e significativa i dati.

Da una prima analisi del contenuto delle tabelle, già si può notare come la feature TLD non sia stata riempita correttamente, infatti, contiene tutti valori null. Fortunatamente è una variabile che non influirà sulle analisi future, dunque la rimoviamo all'interno del dataset, non prendendola in considerazione. Un'altra osservazione importante da esporre è che i dati numerici risultano essere più facili da generare e sono più significativi rispetto a dati qualitativi come le stringhe, dove non sappiamo con certezza se abbia generato dei domini veritieri.


Analisi dei cluster dataset generato da chatGPT

Applicheremo lo stesso processo che è stato applicato al dataset originale sulla variabile URLLength, per notare differenze tra questo dataset e quello originale.

Metodo dell'Elbow



Anche in questo caso con il **metodo dell'elbow** avremo che **K = 2 o K = 3**, ciò significa che avremo bisogno del metodo della silhouette per poter stabilire il numero k di cluster ottimale.



Il grafico della silhouette restituisce come valore ottimale $k = 10$, ma con una distanza molto piccola tra le silhouette medie, ciò significa che comunque non è detto che una separazione così netta di cluster, porterà ad un risultato ottimale. Dunque procederemo con $k = 2$, forti anche dell'analisi fatta con il metodo dell'elbow.

Applicazione del K-means

L'applicazione del k-means è stata fatta anche in questo caso con $k = 2$, $nstart = 10$ e $iter.max = 10$.

Analisi della bontà del clustering

Valutiamo i cluster con le metriche di bontà già utilizzate per il dataset originale.

Table 14: Risultati del Clustering

Metriche	Valori
Centroide Cluster 1	23.92290
Centroide Cluster 2	70.23629
Centroide Globale	40.33096
WCSS	4649321.03445
BCSS	11570438.16589
Calinski-Harabasz	58676.90982

Dai risultati di queste analisi emerge che:

- I due cluster sono ben separati: il **Calinski-Harabasz** e BCSS elevato confermano la distinzione tra URL corti e lunghi;
- Il grado di coesione all'interno di uno stesso cluster è buono, ma potrebbe essere migliore, poiché il WCSS è elevato.

Per il momento i dati rispecchiano ciò che è stato derivato con il dataset originale, bisogna capire ora la centralità e la dispersione di questi dati.

Analisi descrittiva dei cluster generati da ChatGPT

Dopo aver valutato la bontà dei cluster, andiamo a determinare in maniera quantitativa, come sono state divise le osservazioni del dataset.

Table 15: Statistiche descrittive per i due cluster

Clusters	Minimo	Massimo	Media	Mediana	Deviazione_Standard
Cluster1	14	47	23.92290	19	11.16771
Cluster2	48	172	70.23629	66	18.14613

Anche in questo caso i cluster assumono un significato più profondo che ci consente di individuare che:


- **Cluster1:** Questo cluster contiene URL più lunghi, con una variabilità moderata. La mediana vicina alla media suggerisce una distribuzione relativamente bilanciata.
- **Cluster2:** Gruppo di URL moderatamente più corti, con una minore dispersione rispetto al Cluster 1.


In questo caso avremo che i due cluster sono distinti, rispettando gli andamenti visti per i due cluster del dataset originale, ma i dati sono distribuiti in maniera quasi normale poiché chatGPT li ha generati automaticamente in questo modo. Ciò vuol dire che è più complicato avere outliers che influenzino di molto la distribuzione dei dati.

Grafici per confronto cluster

Andiamo a visualizzare le distribuzioni in maniera grafica, per avere una visione più diretta ed esplicativa della differenza tra i due cluster.

Distribuzione dei dati di URLLength per Cluster





Andiamo ad analizzare nel dettaglio il grafico:

- Il Cluster 1 contiene URL relativamente corti, con lunghezze ben distribuite tra 0 e circa 50.
- Il Cluster 2 (azzurro) contiene URL significativamente più lunghi, con una distribuzione che si estende ben oltre 100 caratteri e una maggiore dispersione.
- I valori sono più contenuti, dunque, la dispersione è minore rispetto al dataset originale.
- Il Cluster 2 ha una variabilità elevata, mentre il Cluster 1 è molto più compatto.

Dunque, C'è una netta separazione tra i due cluster, con il cluster 2 che mostra un range di lunghezze molto più ampio rispetto al cluster 1.

Confrontando il clustering applicato sul dataset originale, rispetto a quello applicato sul dataset generato da ChatGPT avremo che:

- Nel dataset sintetico, i cluster sembrano essere più **nettamente separati** e con meno varianza interna.
- Nel dataset reale, il cluster 2 mostra una **variabilità molto più ampia**, con outlier che superano i 1000 caratteri.
- I dati generati da ChatGPT sembrano sottostimare la lunghezza estrema degli URL, mancando gli outlier evidenti nel dataset reale. Infatti il clustering nei dati generati risulta essere più regolare e meno rumoroso rispetto alla realtà.

Il dataset generato da ChatGPT semplifica la distribuzione della lunghezza degli URL, evitando la presenza di valori estremi che invece si trovano nel dataset reale. Questo potrebbe influenzare l'accuratezza di modelli basati su questi dati, specialmente se i pattern delle lunghezze degli URL sono critici per distinguere siti legittimi da siti di phishing.

Inoltre, visualizzando la distribuzione dei dati generati da ChatGPT notiamo che, vengono generati dati che non rispettano quello che è l'andamento reale dei dati, poiché abbiamo una maggiore frequenza di un singolo valore (14), e poi il resto dei dati si assesta su valori simili. Ciò è dovuto dal fatto che ChatGPT cerca di introdurre e riempire i dati in maniera automatica e quindi nella maggior parte dei casi sceglie di inserire un valore comune, poiché è più veloce e semplice.

Inferenza Statistica

Stima dei parametri

Usiamo il modello di regressione logistica per la stima dei parametri che influenzano la probabilità che un URL sia phishing o legittimo. Attraverso il metodo della massima verosimiglianza, andiamo a i coefficienti (β) per URLLength e NoOfOtherSpecialCharsInURL, permettendo di quantificare il loro impatto sulla classificazione.

Regressione logistica

Andiamo a verificare se e come **URLLength** e **NoOfOtherSpecialCharsInURL** influenzano **label**. Per fare ciò utilizzeremo un modello di regressione logistico poiché la variabile sotto analisi è una variabile binaria, sulla quale non si può applicare regressione lineare.

Table 16: Risultati della regressione logistica

Parametro	β (Coefficiente)	Errore Standard	Z-value	P-value	Odds Ratio
Intercept	3.307561	0.066831	49.492	< 2e-16	27.3184202
URLLength	-0.011499	0.002612	-4.403	1.07e-05	0.9885664
NoOfOtherSpecialCharsInURL	-1.437189	0.025278	-56.855	< 2e-16	0.2375946

La tabella mostra i risultati della regressione logistica per la classificazione di phishing (0) vs legittimo (1) in base a URLLength e NoOfOtherSpecialCharsInURL. Ecco il significato di ogni colonna:

1. Parametro

- **Intercept**: Costante del modello;
- **URLLength**: Lunghezza dell'URL;
- **NoOfOtherSpecialCharsInURL**: Numero di caratteri speciali nell'URL.

2. Coefficiente (β): Indica quanto la variabile influenza la probabilità che l'URL sia legittimo (label = 1). Vediamo nel dettaglio i dati:

- **Intercept**: Se un URL avesse lunghezza 0 e nessun carattere speciale, sarebbe molto probabile che sia legittimo;
- **URLLength**: Un aumento della lunghezza dell'URL riduce la probabilità che l'URL sia legittimo;
- **NoOfOtherSpecialCharsInURL**: Un aumento di 1 carattere nella lunghezza dell'URL aumenta la probabilità di phishing di circa il 1.14

3. Errore Standard: Indica la variabilità del coefficiente stimato. Valori piccoli suggeriscono che la stima è precisa.

4. Z-value: Indica quanto è distante il coefficiente da 0, in termini di deviazioni standard. Valori molto alti (in valore assoluto) indicano che il coefficiente è molto significativo.

5. P-value: Indica quanto è probabile che il coefficiente sia diverso da 0 per puro caso. Se $p < 0.05$, la variabile è statisticamente significativa a livello alpha fissato pari a 0.05. Qui, tutte le variabili hanno **p-value < 0.001**, quindi hanno un impatto significativo.

6. Odds Ratio (e^β): Rappresenta quanto cambia la probabilità di essere legittimo quando la variabile aumenta di 1 unità. Vediamo nel dettaglio i dati:

- **Intercept:** Un URL senza caratteri speciali e con lunghezza zero è molto probabile che sia legittimo.
- **URLLength:** Un URL più lungo riduce la probabilità di essere legittimo di circa 1.14%
- **NoOfOtherSpecialCharsInURL:** Aggiungere un carattere speciale riduce del 76% la probabilità di essere legittimo (quindi aumenta di molto la probabilità di phishing).

L'Odds Ratio ha mostrato che gli URL più lunghi e con più caratteri speciali sono fortemente associati al phishing, confermando l'importanza di queste variabili nel modello predittivo.

In conclusione:

- **Gli URL più lunghi tendono ad essere più di phishing;**
- **Gli URL con più caratteri speciali sono fortemente associati al phishing.**

Andiamo a testare il nostro modello, con la creazione di un dataframe che simula un sito con un URL lungo 100 caratteri e che contiene 5 altri caratteri speciali non comuni.

La probabilità che esso sia legittimo è 0.0065, ciò indica che il modello predice in maniera corretta che il sito sarà di phishing

Verifica delle ipotesi

Applicazione criterio del chi quadro per distribuzione normale

L'obiettivo di questo test è verificare se la distribuzione della lunghezza degli URL segue una distribuzione normale. Questo è fondamentale perché molte analisi statistiche assumono una distribuzione normale dei dati; se questa ipotesi non è valida, dovremmo considerare alternative più adatte per rappresentare il fenomeno analizzato. Per fare questa analisi, utilizziamo il test del Chi-Quadrato, confrontando la distribuzione osservata con quella teorica.

Nel test del Chi-Quadrato, abbiamo due ipotesi da verificare:

Ipotesi Nulla (H_0): La distribuzione della lunghezza degli URL segue una distribuzione normale.

Ipotesi Alternativa (H_1): La distribuzione della lunghezza degli URL NON segue una distribuzione normale.

Table 17: Risultati test Chi-Quadrato

Descrizione	Valore
Media URLLength	3.502048e+01
Deviazione Standard URLLength	3.379185e+01
Chi-Quadrato	2.095722e+04
valore critico inferiore	5.063560e-02
valore critico superiore)	7.377759e+00

Il test del Chi-Quadrato confronta le frequenze osservate nei dati reali con quelle attese sotto una distribuzione normale. Per fare ciò:

- È stata calcolata la media e la deviazione standard della variabile URLLength.
- Sono stati determinati quattro valori di soglia basati sulla distribuzione normale, suddividendo la variabile in cinque intervalli di frequenza.

- È stato applicato il test del chi-quadrato per verificare la bontà di adattamento della distribuzione dei dati alla normale attesa.
- Sono stati calcolati i valori critici del chi-quadrato per un livello di significatività $\alpha = 0.05$.

La statistica del Chi-Quadrato calcolata è molto elevata, indicando una forte discrepanza tra le frequenze osservate e quelle attese sotto la normale.

Il p-value risulta estremamente basso (<0.05), indicando che la probabilità che questa discrepanza sia dovuta al caso è praticamente nulla.

Dunque il test fornisce evidenza sufficiente per rifiutare l'ipotesi nulla H_0 , quindi la distribuzione della lunghezza degli URL non segue una distribuzione normale.

Applicazione criterio del chi quadro per distribuzione di Bernoulli

Poiché il test del Chi-Quadrato ha mostrato che la lunghezza degli URL non segue una distribuzione normale, vogliamo confrontarla con un'altra distribuzione che potrebbe descriverla meglio: la distribuzione di Bernoulli. La normale è una distribuzione continua, mentre la Bernoulli è discreta e adatta a variabili binarie (0/1). Per effettuare questo confronto, binarizziamo la lunghezza degli URL in due categorie:

Corto (0): URL con lunghezza inferiore a una soglia (upper bound IQR). Lungo (1): URL con lunghezza superiore alla stessa soglia.

In questo caso quindi le ipotesi sono:

Ipotesi Nulla (H_0): La distribuzione binarizzata della lunghezza degli URL segue una distribuzione di Bernoulli con parametro p . Ciò significa che le frequenze osservate di URL lunghi e corti corrispondono alle frequenze attese sotto una distribuzione di Bernoulli con la probabilità stimata p .

Ipotesi Alternativa (H_1): La distribuzione binarizzata della lunghezza degli URL NON segue una distribuzione di Bernoulli con parametro p .

Il p-value misura la probabilità che le differenze tra osservato e atteso siano dovute al caso. Il p-value = 1 indica che i dati osservati sono perfettamente compatibili con la distribuzione Bernoulli ipotizzata, quindi non c'è alcuna evidenza per rifiutare l'ipotesi nulla H_0 . Quindi possiamo concludere che la distribuzione binarizzata della lunghezza degli URL segue una distribuzione di Bernoulli.

Test Chi-Quadrato su URLLength

Ora che abbiamo stabilito che la variabile binarizzata della lunghezza degli URL segue una distribuzione Bernoulli, vogliamo capire se esiste un'associazione tra la lunghezza dell'URL e la probabilità che un sito sia di phishing.

Per fare questo, utilizzeremo il test del Chi-Quadrato, che permette di valutare se due variabili categoriali sono indipendenti o se esiste una relazione statistica significativa tra di esse. Nel nostro caso, analizzeremo l'associazione tra:

- **URLLength_Cat**: Variabile URLLength suddivisa in due categorie, URL lunghi e URL corti. Il valore che discriminerà le due categorie sarà il limite superiore calcolato nel metodo dell'IQR.
- **label**: Variabile categoriale che distingue URL legittimi, da URL di phishing.

Definiamo le nostre due ipotesi, dove H_0 sarà l'ipotesi nulla e H_1 l'ipotesi alternativa:

- H_0 : La lunghezza dell'URL e la probabilità di phishing sono indipendenti; - H_1 : C'è un'associazione significativa tra URL lunghi e phishing.

Se il **p-value** < **0.05**, rifiutiamo H_0 e concludiamo che gli URL lunghi sono significativamente più associati a siti di phishing.

Table 18: Risultati test Chi-Quadrato

Metrica	Valore
X-squared	3710.6
Gradi di Libertà	1
p-value	< 2.2e-16

I risultati del test mostrano come Il valore X^2 è molto alto, indicando una forte deviazione dall'indipendenza e Il **p-value** < **2.2e-16** è **estremamente piccolo**, quindi possiamo rifiutare l'ipotesi nulla e concludere che esiste una relazione significativa tra la lunghezza degli URL e il fatto che siano di phishing.

Test Chi-Quadrato su NoOfOtherSpecialCharsInURL

Anche in questo caso, utilizzeremo il test del chi-quadrato che verifica l'associazione tra due variabili categoriali che sono:

- **NoOfOtherSpecialCharsInURL_Cat**: Variabile NoOfOtherSpecialCharsInURL suddivisa in due categorie, NoOfOtherSpecialCharsInURL > 6 NoOfOtherSpecialCharsInURL <= 6. Il valore che discriminerà le due categorie sarà il limite superiore calcolato nel metodo dell'IQR.
- **label**: Variabile categoriale che distingue URL legittimi, da URL di phishing.

Definiamo le nostre due ipotesi, dove H_0 sarà l'ipotesi nulla e H_1 l'ipotesi alternativa:

- H_0 : Il numero di altri caratteri speciali in un URL e la probabilità di phishing sono indipendenti; - H_1 : C'è un'associazione significativa tra il numero di altri caratteri speciali in un URL e phishing.

Se il **p-value** < **0.05**, rifiutiamo H_0 e concludiamo che gli URL con una frequenza elevata di altri caratteri speciali sono significativamente più associati a phishing.

Table 19: Risultati test Chi-Quadrato

Metrica	Valore
X-squared	1812.6
Gradi di Libertà	1
p-value	< 2.2e-16

Anche in questo caso, i risultati del test mostrano come Il valore X^2 è molto alto, indicando una forte deviazione dall'indipendenza e Il **p-value** < **2.2e-16** è **estremamente piccolo**, quindi possiamo rifiutare l'ipotesi nulla e concludere che esiste una relazione estremamente significativa tra la frequenza elevata di altri caratteri speciali e il phishing.

Conclusioni

//Mettere risposte RQ con conclusioni finali.